



Modelo Vetorial e BM25 na coleção Cranfield: pré-processamento, parametrização e análise de erros

Autores:

Victor Silva Botelho	N.º USP: 15645421	victorbotelho@usp.br
João Pedro Barbosa Madeira	N.º USP: 13683038	JoaoPEDRO08madeira@gmail.com

Curso: SCC0282 - Recuperação da Informação (2026/2)

Professor: Prof. Marcelo Garcia Manzato

25 de setembro de 2026

1. Introdução

Sistemas de recuperação de informação precisam ordenar uma coleção inteira a partir de uma consulta curta e ambígua. Os modelos clássicos resolvem isso de maneiras distintas: o modelo vetorial representa documentos e consultas como vetores de pesos TF-IDF e ordena pela similaridade do cosseno, enquanto o BM25 parte do arcabouço probabilístico e pondera cada termo com saturação de frequência e normalização explícita por comprimento. Embora ambos valorizem termos raros e controlem a influência da frequência, fazem-no de formas diferentes, e é justamente essa diferença que este trabalho procura tornar visível.

O objetivo é construir e avaliar um sistema de recuperação textual sobre a coleção Cranfield, comparando estratégias de pré-processamento, os dois modelos de ranqueamento e a parametrização do BM25 e, mais importante, explicar por que os comportamentos observados ocorrem, com base em exemplos concretos. A principal conclusão é que, nesta coleção, quase toda a discordância entre os dois modelos é explicada por um único mecanismo: a forma como cada um normaliza o comprimento dos documentos. Essa hipótese é levantada a partir da inspeção de consultas individuais e depois confirmada quantitativamente sobre as 225 consultas.

2. Técnicas Utilizadas

2.1 Pré-processamento

O texto passa por normalização para minúsculas e tokenização por expressão regular `[a-z]+`, que é determinística e adequada ao texto técnico ASCII do Cranfield. A escolha tem um efeito colateral relevante: hifens viram separadores, de modo que `boundary-layer-control` gera três tokens e `photo-thermoelastic` gera `photo` e `thermoelast`, fato que reaparece na Seção 4.6. A remoção de stopwords usa a lista `english` do NLTK (198 formas, expandidas para fragmentos alfabéticos) e o stemming usa o algoritmo de Porter. As stopwords são removidas antes do stemming, pois a lista é definida sobre formas plenas e o radical de uma stopword pode coincidir com o de um termo de conteúdo.

2.2 Modelo Vetorial

Adotamos o esquema apresentado em aula (l_{tc}.l_{tc} na notação SMART), aplicado igualmente a documentos e consultas:

$$w_{i,j} = (1 + \log_{10} f_{i,j}) \times \log_{10} \frac{N}{n_i}$$

Cada documento é um vetor de dimensão $|V| = 4292$, com uma coordenada por termo do vocabulário e praticamente todas nulas. O score é a similaridade do cosseno,

$$\text{sim}(d, q) = \frac{d \cdot q}{\|d\| \|q\|},$$

em que o numerador mede o alinhamento entre consulta e documento e o denominador remove o efeito da magnitude. Como normalizamos os vetores para norma unitária já na indexação, o cosseno se reduz a um produto interno: é o mesmo cálculo, reorganizado para ser feito de uma vez sobre os 1400 documentos. Note que o idf vale exatamente zero para um termo presente em toda a coleção, que assim é eliminado do ranking.

2.3 BM25

O BM25 foi implementado explicitamente, termo a termo, sem biblioteca de ranqueamento:

$$\text{score}(d, q) = \sum_{t \in q} \text{IDF}(t) \frac{f_{t,d} (k_1 + 1)}{f_{t,d} + k_1 \left(1 - b + b \frac{|d|}{\text{avgl}} \right)}.$$

O quociente cresce com a frequência mas satura em $k_1 + 1$, ao contrário do tf logarítmico do modelo vetorial; k_1 controla quão rápido essa saturação ocorre (com $k_1 = 0$ o modelo vira binário) e b interpola entre nenhuma normalização por comprimento ($b = 0$) e normalização integral ($b = 1$). Somamos a contribuição de um termo tantas vezes quanto ele ocorre na consulta, o que equivale a $k_3 \rightarrow \infty$. Usamos o IDF de Robertson suavizado, $\log \left(1 + \frac{N-n+0.5}{n+0.5} \right)$, cujo “+” impede valores negativos para termos muito frequentes.

Vale registrar uma identidade algébrica que explica um resultado nosso: aquela expressão é idêntica a $\log \frac{N+1}{n+0.5}$, ao passo que a forma do BIM vista em aula é $\log \frac{N+0.5}{n+0.5}$. As duas diferem apenas por uma constante aditiva $\log \frac{N+1}{N+0.5} \approx 0,00036$ em todos os termos. Por isso, ao testarmos as duas variantes, o MAP mudou apenas na sexta casa decimal (0,304827 contra 0,304821): a escolha entre elas é irrelevante nesta coleção, e o motivo é algébrico, não empírico.

2.4 Decisões de implementação

Índice compartilhado. Ambos os modelos derivam seus pesos da mesma matriz esparsa de frequências brutas, garantindo que qualquer diferença venha da função de ranqueamento e não da indexação. **Texto indexado:** em 1395 dos 1400 documentos o campo `.W` já começa com o título; concatenar `.T` dobraria o tf dos termos do título, então só o fazemos quando o título ainda não é prefixo do resumo. **De-sempate determinístico:** scores iguais são ordenados pelo `doc_id` crescente, de modo que duas execuções produzem rankings idênticos.

3. Avaliação

Coleção. Cranfield: 1400 documentos de aerodinâmica, 225 consultas em linguagem natural e 1837 julgamentos de relevância, obtida dos arquivos originais da University of Glasgow. Cada consulta tem entre 1 e 39 documentos relevantes (média 7,2), e nenhuma fica sem relevantes.

Dois detalhes da coleção exigem cuidado. Primeiro, os identificadores `.I` das consultas não são sequenciais (001, 002, 004, ..., 365), mas o arquivo `cranqrel` numera as consultas de 1 a 225 pela posição no arquivo; usar o `.I` como chave desalinha silenciosamente consultas e julgamentos. Renumeramos por posição, como faz o `ir_datasets`. Segundo, a escala de relevância do Cranfield é invertida: o grau 1 é o melhor (“resposta completa”) e o 4 é o pior (“interesse mínimo”).

Relevância. Para as métricas binárias seguimos o enunciado: relevante $\Leftrightarrow$ grau ≥ 1 ; graus -1 e documentos não julgados contam como não relevantes. Para o NDCG mantivemos os graus positivos como relevância graduada, mas corrigindo a inversão ($1 \rightarrow 4$, $2 \rightarrow 3$, $3 \rightarrow 2$, $4 \rightarrow 1$): usar o grau bruto daria o maior ganho ao documento menos relevante. A diferença não é cosmética: o NDCG@10 do BM25

vale 0,355 com o mapeamento corrigido e apenas 0,304 com o grau bruto.

Métricas. P@10, R@10, F1@10, MAP, MRR e NDCG@10, definidas como em aula: $AP(q) = \frac{1}{|R_q|} \sum_k P@k \cdot \text{rel}(k)$, com $|R_q|$ contando todos os relevantes (relevantes não recuperados penalizam a métrica); $DCG@k = \sum_i \frac{2^{\text{rel}_i} - 1}{\log_2(i+1)}$; e curva precisão-revocação interpolada em 11 pontos por $P(r) = \max_{r' \geq r} P(r')$. Todas foram implementadas por nós e validadas contra os valores calculados à mão no exercício do slide 41 da Aula 05.

Configuração experimental. O ranking é calculado sobre os 1400 documentos e os cortes @10 aplicados só na avaliação. Os qrels são usados exclusivamente para avaliar: nenhuma etapa de indexação, ponderação, escolha de parâmetros ou reformulação os consulta. A configuração principal usa o pré-processamento vencedor da Seção 4.1 e $k_1 = 1,2$, $b = 0,75$.

Verificação da implementação. Uma versão ingênua em Python puro, escrita com laços diretamente a partir das fórmulas, reproduz os scores da versão vetorizada em SciPy com tolerância 10^{-10} , para os dois modelos e três combinações de (k_1, b) . O modelo vetorial também foi comparado ao `TfidfVectorizer` do scikit-learn (correlação de Spearman $> 0,95$; não se espera igualdade exata porque o scikit-learn usa $\text{idf} = \ln(N/\text{df}) + 1$). São 16 testes, em `tests/test_ir_tp1.py`.

4. Resultados Obtidos e Análise

4.1 Pré-processamento

O ganho é monotônico nas quatro configurações e vale para os dois modelos (Tabela 1 e Figura 1): o MAP do BM25 sobe de 0,269 (linha de base) para 0,283 com stopwords, 0,295 com stemming e 0,305 com ambos, ganho total de 13,2%. Os dois efeitos são complementares, e não redundantes, porque atacam problemas diferentes.

Configuração	V	d méd.	MAP vet.	MAP BM25	P@10 BM25
sem stopw./sem stem.	7044	159,1	0,243	0,269	0,216
stopwords	6925	92,1	0,250	0,283	0,226
stemming	4403	159,1	0,262	0,295	0,226
stopwords + stem.	4292	92,1	0,276	0,305	0,234

Tabela 1: Efeito do pré-processamento. |V| é o tamanho do vocabulário e |d| méd. o comprimento médio dos documentos em tokens.

A Tabela 1 deixa o mecanismo visível. A remoção de stopwords quase não altera o vocabulário (7044 → 6925 termos, pois a lista tem só 198 formas) mas elimina 42% de todos os tokens (comprimento médio 159,1 → 92,1): o efeito é sobre o denominador das normalizações, já que a norma do cosseno e o $|d|/\text{avgdl}$ do BM25 deixam de ser dominados por palavras sem poder discriminativo. Já o stemming não remove token algum, mas funde formas flexionadas e reduz o vocabulário em 38% (7044 → 4403): o efeito é sobre a cobertura do casamento léxico, permitindo que uma consulta com `solutions` case com um documento que diz `solution`. Como um ataca a normalização e o outro a cobertura, somam-se. Vale notar que o stemming sozinho (0,295) supera as stopwords sozinhas (0,283), o que é coerente com uma coleção de textos científicos, onde a variação

morfológica é intensa. Todos os resultados seguintes usam a configuração vencedora (stop + stem).




Figura 1: MAP e P@10 nas quatro configurações de pré-processamento.

4.2 Comparação entre os modelos

Modelo	P@10	R@10	F1@10	MAP	MRR	NDCG@10
Vetorial	0,217	0,378	0,249	0,276	0,487	0,326
BM25	0,234	0,398	0,266	0,305	0,539	0,355
Δ relativo	+8,0%	+5,0%	+7,0%	+10,3%	+10,7%	+8,7%

Tabela 2: Métricas agregadas sobre as 225 consultas.

A Tabela 2 mostra que o BM25 é superior em todas as métricas, com vantagem maior no MRR (+10,7%) e no MAP (+10,3%), ou seja, ganha sobretudo no topo do ranking. A curva precisão-revocação (Figura 2) mostra que a vantagem se mantém em todos os 11 níveis de revocação, e não apenas em média.

A média, porém, esconde o essencial: o BM25 vence em 137 consultas, perde em 81 e empata em 7. A dispersão da Figura 3 confirma que há um número expressivo de consultas abaixo da diagonal. A pergunta interessante não é qual modelo tem a maior média, mas o que separa as consultas dos dois grupos.




Figura 2: Curva precisão × revocação interpolada em 11 pontos.

4.3 Análise por consulta

A seleção é automática: entre as consultas com ao menos 4 relevantes, as duas de maior e menor ΔAP e as duas de menor AP médio. Lendo os Top-5 da Tabela 3 lado a lado,

Caso	Q	Mod	1°	2°	3°	4°	5°	AP
BM25	> q223	vet.	1008	864	1399	400*	1359	0,19
vet.								
BM25	> q59	vet.	1399	400*	1398*	419	1387*	0,46
vet.			382	383	842	786*	1154	0,11
BM25	> q113	vet.	785*	381	1154	149	786*	0,37
vet.			265*	748*	594	1272	716	0,51
BM25	> q190	vet.	704	815	748*	638	708	0,15
vet.			390*	391*	1008	15*	627	0,72
BM25	q124	vet.	390*	627	856	1339	15*	0,38
vet.			941	898	938	1070	516	0,00
BM25	q13	vet.	941	516	898	442	934	0,00
vet.			496	903	520	643	313	0,01
BM25			496	903	520	313	440	0,01

Tabela 3: Top-5 de cada modelo nas seis consultas selecionadas. Identificadores de documento; **negrito*** = relevante (grau ≥ 1).

aparece um padrão nítido, e é um padrão de comprimento de documento.

(i) **BM25 claramente superior: q223 e q59.** Em q223 (*shear buckling of unstiffened rectangular plates*), o modelo vetorial coloca no topo os documentos 1008 (51 tokens) e 864 (29 tokens), ambos irrelevantes e muito curtos, e só encontra um relevante na 4ª posição. O BM25 recupera na 3ª e 5ª posições os documentos 1398 (115 tokens) e 1387 (120 tokens), ambos relevantes e longos. A causa é a normalização: o cosseno divide pela norma completa do vetor, o que penaliza integralmente um documento longo, mesmo quando o comprimento vem de tratar o assunto com profundidade; o BM25 com $b = 0,75$ normaliza apenas parcialmente. Em q59 ocorre o mesmo: o vetorial promove o documento 382 (21 tokens) e o BM25 encontra o relevante 785 já na 1ª posição.

(ii) **Modelo vetorial superior: q113 e q190.** O mecanismo é o mesmo, com o sinal trocado. Em q113 o BM25 traz para o topo os documentos 704 (185 tokens), 815 (142) e 638 (138), todos longos e todos irrelevantes, enquanto o vetorial acerta as duas primeiras posições com os documentos 265 (49 tokens) e 748 (83). Aqui os relevantes são curtos e específicos, e a normalização integral do cosseno é exatamente o que se quer. Em q190 o vetorial coloca três relevantes no Top-4 e o BM25 intercala os documentos 856 (137) e 1339 (130), não relevantes. Em outras palavras: a normalização parcial do BM25 é uma aposta, que paga bem quando os relevantes são longos e custa caro quando são curtos.

(iii) **Ambos insatisfatórios: q124 e q13.** Estas revelam limitações que nenhum ajuste de ranqueamento resolve. A q13 (*what is the basic mechanism of the transonic aileron buzz*) tem, na 1ª posição de ambos os modelos, o documento 496, “a theory of transonic aileron buzz, neglecting viscous effects”. O casamento léxico é quase perfeito, e mesmo assim o julgamento é -1, isto é, não relevante. A q124 é uma consulta composta, com duas necessidades de informação distintas (escoamento em canais delgados e estabilidade de cascas cônicas); o documento 941, cujo título praticamente repete a primeira metade da consulta, também é julgado -1. Ou seja, o erro não está no ranqueamento, mas no descompasso entre sobreposição léxica e relevância julgada: o avaliador julgou contra a necessidade real, que os modelos

não enxergam.

4.4 Verificando a hipótese do comprimento

A leitura acima é uma hipótese construída sobre seis consultas. Testamo-la sobre as 225. Se a normalização for mesmo o mecanismo dominante, então (a) o Top-10 do BM25 deve ser em média mais longo que o do vetorial e (b) o BM25 deve levar vantagem justamente nas consultas cujos relevantes são longos.

Ambas se confirmam. O comprimento médio da coleção é 92,1 tokens e o dos documentos relevantes é 92,5, praticamente idêntico, ou seja, ser longo não torna um documento relevante. Ainda assim, o Top-10 do modelo vetorial tem em média 79,4 tokens (bem abaixo da média da coleção) e o do BM25, 98,4 (acima). O vetorial tem, portanto, **um viés sistemático para documentos curtos que não é justificado pelos dados**. E a correlação de Spearman entre ΔAP (BM25 – vetorial) e o comprimento médio dos relevantes de cada consulta é $\rho = 0,432$ ($p \approx 1 \times 10^{-11}$, $n = 225$). A hipótese levantada a partir de seis exemplos resiste, portanto, a um teste sobre a coleção inteira.




Figura 3: AP por consulta. Pontos acima da diagonal favorecem o BM25.

4.5 Variação dos parâmetros do BM25

$k_1 \backslash b$	0 (MAP)	0,75 (MAP)	1 (MAP)	0,75 (P@10)	0,75 (NDCG)
0,5	0,268	0,291	0,294	0,221	0,338
1,2	0,277	0,305	0,306	0,234	0,355
2,0	0,281	0,312	0,308	0,241	0,363

Tabela 4: Grade $k_1 \times b$. As três últimas colunas fixam $b = 0,75$.

O melhor ponto da grade (Tabela 4 e Figura 4) é $k_1 = 2,0$, $b = 0,75$, com MAP 0,312 e P@10 0,241. O resultado mais claro é que **b importa muito mais que k_1** : fixado k_1 , passar de $b = 0$ para $b = 0,75$ melhora o MAP entre 8,6% e 10,8%, enquanto variar k_1 de 0,5 a 2,0 com b fixo rende no máximo 7%. Coerente com a Seção 4.4, a normalização por comprimento é o fator dominante nesta coleção. Também há interação entre os parâmetros: para k_1 pequeno (0,5 e 1,2) o melhor b é 1,0, mas para $k_1 = 2,0$ o melhor é 0,75. A leitura é que k_1 alto deixa o score mais sensível à frequência bruta, e aí uma normalização total ($b = 1$) passa a penalizar demais




Figura 4: MAP do BM25 na grade de parâmetros. A cor codifica a magnitude; o valor está impresso em cada célula.

documentos longos que acumulam ocorrências legítimas; um pouco de folga ($b = 0,75$) compensa.

Efeito de b em uma consulta concreta. A q67 (“*can series expansions be found for the boundary layer on a flat plate in a...*”, 14 relevantes) é o caso mais didático.

b	1º	2º	3º	4º	5º	AP
0,0	9	72	1107	155	2*	0,14
0,75	393*	180*	4*	3*	306	0,49
1,0	3*	393*	180*	4*	664*	0,55

Tabela 5: Top-5 da consulta q67 para três valores de b ($k_1 = 1,2$).

A Tabela 5 traz os três rankings. Com $b = 0$ não há normalização alguma e o Top-5 é tomado por documentos de 177, 164, 138, 130 e 116 tokens, dos quais apenas o último é relevante: sem normalização, o score cresce com o tamanho, pois documentos longos simplesmente acumulam mais ocorrências dos termos da consulta. Com $b = 0,75$ o ranking se inverte por completo, e os cinco primeiros passam a ter 34, 36, 47, 17 e 91 tokens, sendo quatro deles relevantes. Com $b = 1$ os cinco são relevantes e a AP vai de 0,14 para 0,55. Os documentos relevantes desta consulta são artigos curtos e diretamente sobre o tema (“*the boundary layer in simple shear flow past a flat plate*”, 17 tokens); sem normalização eles são esmagados por textos longos que mencionam os mesmos termos de passagem.

4.6 Reformulação de consultas

Cinco consultas foram reescritas manualmente, cada uma com uma operação diferente e com a hipótese registrada no código antes de rodar os modelos. As duas versões de cada consulta foram executadas com os dois modelos, e a Tabela 6 resume as mudanças no Top-10: as colunas P@10 medem diretamente quantos relevantes entraram ou saíram dessa faixa, e o NDCG@10 acrescenta o efeito de reordenação dentro dela. O Top-10 completo das dez execuções está em `results/05_query_reformulation_detail.json`.

q219, sinônimo. O caso mais limpo. A consulta original diz “... *when the reynolds number is small*”, mas a literatura consagrou a expressão “*low Reynolds number*”. Trocando uma única palavra, *small* por *low*, a AP do vetorial vai de 0,045 para 0,119 e a do BM25 de 0,037 para 0,093, e a P@10, que era zero nos dois modelos, passa a 0,10. A Tabela 7 mostra o efeito no Top-10: na versão original, nenhuma das dez posições traz um relevante nos dois modelos, e as listas são

quase as mesmas (1221, 1222, 208, 299, 993 e 530 aparecem em ambas); na versão modificada o documento 666 (grau 2) entra em 2º no vetorial e em 4º no BM25, com sete das dez posições renovadas no vetorial e seis no BM25. Nada mudou no significado da pergunta; mudou apenas o vocabulário. É a ilustração mais direta da limitação apontada na Aula 04: modelos puramente léxicos não enxergam sinonímia.

q69 e q109, tornar mais específica. Ambas confirmam a hipótese, com ganho modesto. Em q69 os termos originais são todos pouco discriminativos (*solution*, *boundary*, *layer* e *equation* ocorrem em 400 a 470 dos 1400 documentos); acrescentar *series*, *laminar* e *compressible* leva a AP do BM25 de 0,039 a 0,092 e a R@10 de 0 a 0,20. Em q109, uma consulta de apenas 4 tokens, explicitar a consequência física (tensão térmica, flambagem, flutter) leva a P@10 de 0 a 0,10.

q171, remover termos: hipótese parcialmente refutada. Prevíamos que enxugar a consulta de 17 tokens beneficiaria sobretudo o modelo vetorial, prejudicado pela diluição da norma. O vetorial de fato melhorou um pouco (0,306 → 0,319), mas o BM25 piorou (0,639 → 0,556). A explicação é que o BM25 não normaliza o vetor de consulta: termos adicionais só somam evidência, e mesmo termos de IDF baixo contribuem positivamente quando presentes. Remover termos, para o BM25, é descartar evidência sem contrapartida, o que revela uma assimetria entre os modelos que não havíamos previsto.

q15, vocabulário técnico e o valor da métrica graduada. O termo *photoelastic* ocorre em um único documento, mas os dois relevantes usam *photo-thermoelastic*, que o tokenizador quebra em *photo* e *thermoelast*, e o stemming não aproxima essas formas. Adotando o termo dos autores, a AP do BM25 não muda (1,00 → 1,00), porque os dois relevantes já estavam no topo; mas o NDCG@10 sobe de 0,74 para 1,00, pois a reformulação reordenou os dois relevantes, trazendo para a 1ª posição o de grau 1 (“resposta completa”). É um bom argumento a favor de reportar métricas graduadas: a AP é cega a uma melhora que o usuário perceberia.

4.7 Análise de erros

Falsos positivos. Escolhemos documentos não relevantes trazidos pelo BM25 para as duas primeiras posições. (1) Na q98, o documento 638 (“*longitudinal aerodynamic characteristics at low subsonic speeds of a highly swept wing utilizing nose flaps*”, grau -1) aparece em 1º com score 35,1. A decomposição do score mostra de onde ele vem: *flap* (+6,74), *control* (+5,70), *trail* (+4,87), *subson* (+3,03). Todos os termos da consulta estão lá, mas a consulta pergunta se controles na ponta se comparam a flaps de bordo de fuga, e o documento trata de flaps de nariz. É a hipótese de independência entre termos falhando: o modelo soma evidências isoladas e não percebe que a consulta pede uma relação entre elas. (2) Na q124, o documento 941 tem título quase idêntico a metade da consulta e recebe +8,40 só de *channel* ($n = 17$, IDF altíssimo), mas é julgado -1, porque a necessidade real de informação está na outra metade da consulta. (3) Um terceiro caso, na q139, é de outra natureza: os documentos 847 e 897 estão em 1º e 2º e parecem genuinamente pertinentes, mas simplesmente não foram julgados. Como o enunciado manda tratar não julgados como não relevantes,

Cons.	Operação	AP vetorial	P@10 vetorial	AP BM25	P@10 BM25	NDCG@10 BM25
q219	sinônimo	0,04 → 0,12	0,00 → 0,10	0,04 → 0,09	0,00 → 0,10	0,00 → 0,09
q69	+ específica	0,02 → 0,05	0,00 → 0,00	0,04 → 0,09	0,00 → 0,10	0,00 → 0,17
q109	+ específica (curta)	0,03 → 0,04	0,00 → 0,00	0,04 → 0,06	0,00 → 0,10	0,00 → 0,03
q171	– termos	0,31 → 0,32	0,30 → 0,30	0,64 → 0,56	0,30 → 0,30	0,66 → 0,61
q15	vocabulário	0,62 → 0,58	0,20 → 0,20	1,00 → 1,00	0,20 → 0,20	0,74 → 1,00

Tabela 6: Efeito das reformulações no Top-10 (original → modificada).

Pos.	Vetorial original	Vetorial modificada	BM25 original	BM25 modificada
1	1221	670	1221	315
2	1222	666*	208	1221
3	208	537	1222	993
4	299	238	992	666*
5	993	668	993	1082
6	664	535	299	371
7	530	1221	371	139
8	228	139	530	208
9	971	993	7	9
10	197	1222	1309	710

Tabela 7: Top-10 da consulta q219 antes e depois da troca de `small` por `low`. **Negrito*** = relevante (grau ≥ 1).

eles contam como erro, o que é, na verdade, uma limitação de cobertura dos qrels do Cranfield, não do sistema.

Falso negativo. Na q80 (“*are methods of measuring aerodynamic derivatives available which could be adopted for use in short running time facilities*”), o documento 596 tem grau 3 e aparece na posição 1206 em ambos os modelos. O motivo é categórico: a interseção entre os tokens da consulta e os do documento é vazia. O documento se chama “*the properties of crossed flexure pivots...*” e descreve o aparato usado na medição, enquanto a consulta descreve o método e a finalidade. Score zero não é um erro de ponderação: é o limite do casamento léxico. Nenhum ajuste de k_1 , b ou pré-processamento recupera esse documento; seria preciso representação semântica (embeddings) ou expansão de consulta. Os outros dois falsos negativos que examinamos têm a mesma assinatura: no documento 236 da q87 (grau 4), o único termo casado é `flow`, o de menor IDF da consulta ($n = 730$ de 1400).

5. Considerações finais

1. **O pré-processamento é barato e vale a pena.** Stopwords e stemming juntos elevam o MAP do BM25 em 13,2%, e são complementares porque atacam frentes distintas: um corrige o denominador das normalizações, o outro amplia a cobertura do casamento léxico.
2. **O BM25 vence, mas não por ser “melhor” em abstrato.** Ele supera o vetorial em todas as métricas (MAP +10,3%) e em todos os níveis de revocação, mas perde em 81 das 225 consultas. A diferença é governada pela normalização por comprimento: o cosseno normaliza integralmente e adquire um viés para documentos curtos (Top-10 médio de 79,4 tokens contra 92,1 da coleção), enquanto o BM25 normaliza parcialmente. Confirmamos isso com $\rho = 0,43$ entre ΔAP e o comprimento dos relevantes.
3. **b importa mais que k_1 ,** e os dois interagem: o melhor b cai de 1,0 para 0,75 quando k_1 cresce de 1,2 para 2,0.

4. **O teto dos dois modelos é léxico.** As consultas em que ambos falham não falham por ranqueamento: ou o documento relevante não compartilha nenhum termo com a consulta, ou a consulta é composta, ou o julgamento não acompanha a sobreposição léxica. Trocar “*small*” por “*low*” em q219 quase triplicou a AP, um ganho que nenhum ajuste de parâmetro produziria. É exatamente onde entram expansão de consulta e representações densas.

5. **A escolha da métrica muda o diagnóstico.** A AP não viu a melhora da reformulação de q15, que o NDCG@10 registrou (0,74 → 1,00); e o NDCG varia 17% conforme se corrija ou não a escala invertida do Cranfield. Decisões de avaliação merecem tanta atenção quanto decisões de modelagem.

6. Uso de ferramentas de IA

Ferramentas de IA generativa (Claude) foram utilizadas como apoio e somente nas seguintes atividades: (i) **apoio à programação**, na estruturação dos módulos, na vetorização com matrizes esparsas e na escrita dos testes automatizados; (ii) **depuração**, no diagnóstico de uma instalação corrompida do SciPy causada pelo limite de 260 caracteres de caminho do Windows e na identificação do desalinhamento entre os identificadores `.I` das consultas e a numeração do `cranqrel`; (iii) **explicação de conceitos**, na discussão das variantes de IDF do BM25 e das convenções de ganho do NDCG; e (iv) **correção ortográfica** deste relatório. As fórmulas, as decisões de implementação, o desenho dos experimentos, as reformulações manuais de consulta e a interpretação dos resultados foram desenvolvidos, revisados e são de responsabilidade dos autores.

Referências

- [1] MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [2] ROBERTSON, S.; ZARAGOZA, H. *The Probabilistic Relevance Framework: BM25 and Beyond*. Foundations and Trends in IR, 2009.
- [3] SALTON, G.; WONG, A.; YANG, C. S. A Vector Space Model for Automatic Indexing. *Communications of the ACM*, v. 18, n. 11, 1975.
- [4] CLEVERDON, C. W. The Cranfield tests on index language devices. *Aslib Proceedings*, 1967.
- [5] JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated Gain-based Evaluation of IR Techniques. *ACM TOIS*, v. 20, n. 4, 2002.