

Modelo Vetorial e BM25 na coleção Cranfield: pré-processamento, parametrização e análise de erros

<NOME COMPLETO> (<Nº USP>) • <NOME COMPLETO> (<Nº USP>) • <NOME COMPLETO> (<Nº USP>)

Instituto de Ciências Matemáticas e de Computação — Universidade de São Paulo
SCC0282 — Recuperação de Informação — 2º semestre de 2026

<email@usp.br> • <email@usp.br> • <email@usp.br>

1. Introdução

Sistemas de recuperação de informação precisam ordenar uma coleção inteira a partir de uma consulta curta e ambígua. Os modelos clássicos resolvem isso de maneiras distintas: o **modelo vetorial** representa documentos e consultas como vetores de pesos TF-IDF e ordena pela similaridade do cosseno, enquanto o **BM25** parte do arcabouço probabilístico e pondera cada termo com saturação de frequência e normalização explícita por comprimento. Embora ambos valorizem termos raros e controlem a influência da frequência, fazem-no de formas diferentes — e é justamente essa diferença que este trabalho procura tornar visível.

O objetivo é construir e avaliar um sistema de recuperação textual sobre a coleção Cranfield, comparando estratégias de pré-processamento, os dois modelos de ranqueamento e a parametrização do BM25, e — mais importante — explicar *por que* os comportamentos observados ocorrem, com base em exemplos concretos. A principal conclusão é que, nesta coleção, quase toda a discordância entre os dois modelos é explicada por um único mecanismo: a **forma como cada um normaliza o comprimento dos documentos**. Essa hipótese é levantada a partir da inspeção de consultas individuais e depois confirmada quantitativamente sobre as 225 consultas.

2. Técnicas Utilizadas

2.1 Pré-processamento

O texto passa por **normalização para minúsculas** e **tokenização** por expressão regular $[a-z]^+$, que é determinística e adequada ao texto técnico ASCII do Cranfield. A escolha tem um efeito colateral relevante: hifens viram separadores, de modo que *boundary-layer-control* gera três tokens e *photo-thermoelastic* gera *photo* e *thermoelast* — fato que reaparece na §4.6. A **remoção de stopwords** usa a lista *english* do NLTK (198 formas, expandidas para fragmentos alfabéticos) e o **stemming** usa o algoritmo de Porter. As stopwords são removidas *antes* do stemming, pois a lista é definida sobre formas plenas e o radical de uma stopword pode coincidir com o de um termo de conteúdo.

2.2 Modelo Vetorial

Adotamos o esquema apresentado em aula (*ltc.ltc* na notação SMART), aplicado igualmente a documentos e consultas:

$$w(i, j) = (1 + \log_{10} f(i, j)) \times \log_{10} (N / n(i))$$

Cada documento é um vetor de dimensão $|V| = 4292$, com uma coordenada por termo do vocabulário e praticamente todas nulas. O score é a similaridade do cosseno, $\text{sim}(d, q) = (d \cdot q) / (||d|| ||q||)$: o numerador mede o alinhamento entre consulta e documento e o denominador remove o efeito da magnitude. Como normalizamos os vetores para norma unitária já na indexação, o cosseno se reduz a um produto interno — é o mesmo cálculo, reorganizado para ser feito de uma vez sobre os 1400 documentos. Note que *idf* vale exatamente zero para um termo presente em toda a coleção, que assim é eliminado do ranking.

2.3 BM25

O BM25 foi implementado explicitamente, termo a termo, sem biblioteca de ranqueamento:

$$\text{score}(d, q) = \sum \text{IDF}(t) \cdot f(t, d) (k_1 + 1) / [f(t, d) + k_1 (1 - b + b \cdot |d| / \text{avgdl})]$$

O quociente cresce com a frequência mas **satura** em $k_1 + 1$, ao contrário do *tf* logarítmico do modelo vetorial; k_1 controla quão rápido essa saturação ocorre (com $k_1 = 0$ o modelo vira binário) e b interpola entre nenhuma normalização por comprimento ($b = 0$) e normalização integral ($b = 1$). Somamos a contribuição de um termo tantas vezes quanto ele ocorre na consulta, o que equivale a $k_3 \rightarrow \infty$. Usamos o *IDF* de Robertson suavizado, $\log(1 + (N - n + 0,5) / (n + 0,5))$, cujo “1 +” impede valores negativos para termos muito frequentes.

Vale registrar uma identidade algébrica que explica um resultado nosso: aquela expressão é idêntica a $\log((N+1)/(n+0,5))$, ao passo que a forma do BIM vista em aula é $\log((N+0,5)/(n+0,5))$. As duas diferem apenas por uma constante aditiva $\log((N+1)/(N+0,5)) \approx 0,00036$ em todos os termos. Por isso, ao testarmos as duas variantes, o MAP mudou apenas na sexta casa decimal (0,304827 contra 0,304821) — a escolha entre elas é irrelevante nesta coleção, e o motivo é algébrico, não empírico.

2.4 Decisões de implementação

Índice compartilhado. Ambos os modelos derivam seus pesos da mesma matriz esparsa de frequências brutas, garantindo que qualquer diferença venha da função de ranqueamento e não da indexação. **Texto indexado:** em 1395 dos 1400 documentos o campo *.W* já começa com o título; concatenar *.T* dobraria o *tf* dos termos do título, então só o fazemos quando o título ainda não é prefixo do resumo. **Desempate determinístico:** scores iguais são ordenados pelo *doc_id* crescente, de modo que duas execuções produzem rankings idênticos.

3. Avaliação

Coleção. Cranfield: 1400 documentos de aerodinâmica, 225 consultas em linguagem natural e 1837 julgamentos de relevância, obtida dos arquivos originais da University of Glasgow. Cada consulta tem entre 1 e 39 documentos relevantes (média 7,2), e nenhuma fica sem relevantes.

Dois detalhes da coleção que exigem cuidado. Primeiro, os identificadores *.I* das consultas *não são sequenciais* (001, 002, 004, ..., 365), mas o arquivo *cranqrel* numera as consultas de 1 a 225 pela *posição* no arquivo; usar o *.I* como chave desalinha silenciosamente consultas e julgamentos. Renumeramos por posição, como faz o *ir_datasets*. Segundo, a escala de relevância do Cranfield é *invertida*: o grau 1 é o melhor (“resposta completa”) e o 4 é o pior (“interesse mínimo”).

Relevância. Para as métricas binárias seguimos o enunciado: relevante $\Leftrightarrow$ grau ≥ 1 ; graus -1 e documentos não julgados contam como não relevantes. Para o NDCG mantivemos os graus positivos como relevância graduada, mas *corrigindo a inversão* (1 $\rightarrow$ 4, 2 $\rightarrow$ 3, 3 $\rightarrow$ 2, 4 $\rightarrow$ 1): usar o grau bruto daria o maior ganho ao documento menos relevante. A diferença não é cosmética — o NDCG@10 do BM25 vale 0,355 com o mapeamento corrigido e apenas 0,304 com o grau bruto.

Métricas. $P@10$, $R@10$, $F1@10$, MAP, MRR e NDCG@10, definidas como em aula: $AP(q) = (1/|R_q|) \cdot \sum P@k \cdot \text{rel}(k)$, com $|R_q|$ contando *todos* os relevantes (relevantes não recuperados penalizam a métrica); $DCG@k = \sum (2^{\text{rel}-1}) / \log_2(i+1)$; e curva precisão-revocação interpolada em 11 pontos por $P(r) = \max_{\{r' \geq r\}} P(r')$. Todas foram implementadas por nós e validadas contra os valores calculados à mão no exercício do slide 41 da Aula 05.

Configuração experimental. O ranking é calculado sobre os 1400 documentos e os cortes @10 aplicados só na avaliação. Os greis são usados *exclusivamente para avaliar*: nenhuma etapa de indexação, ponderação, escolha de parâmetros ou reformulação os consulta. A configuração principal usa o pré-processamento vencedor da §4.1 e $k_1 = 1,2$, $b = 0,75$.

Verificação da implementação. Uma versão ingênua em Python puro, escrita com laços diretamente a partir das fórmulas, reproduz os scores da versão vetorizada em SciPy com tolerância 10^{-10} , para os dois modelos e três combinações de (k_1, b) . O modelo vetorial também foi comparado ao `TfidfVectorizer` do `scikit-learn` (correlação de Spearman $> 0,95$; não se espera igualdade exata porque o `scikit-learn` usa $\text{idf} = \ln(N/\text{df}) + 1$). São 16 testes, em `tests/test_ir_tp1.py`.

4. Resultados Obtidos e Análise

4.1 Pré-processamento

O ganho é **monotônico** nas quatro configurações e vale para os dois modelos: o MAP do BM25 sobe de 0,269 (linha de base) para 0,283 com stopwords, 0,295 com stemming e 0,305 com ambos — ganho total de 13,2%. Os dois efeitos são *complementares*, e não redundantes, porque atacam problemas diferentes.

Configuração	V	d méd.	MAP vet.	MAP BM25	P@10 BM25
sem stopw./sem stem.	7044	159,1	0,243	0,269	0,216
stopwords	6925	92,1	0,250	0,283	0,226
stemming	4403	159,1	0,262	0,295	0,226
stopwords + stem.	4292	92,1	0,276	0,305	0,234

Tabela 1. Efeito do pré-processamento. |V| é o tamanho do vocabulário e |d| méd. o comprimento médio dos documentos em tokens.

A tabela deixa o mecanismo visível. A remoção de stopwords quase não altera o vocabulário (7044 → 6925 termos, pois a lista tem só 198 formas) mas elimina **42% de todos os tokens** (comprimento médio 159,1 → 92,1): o efeito é sobre o *denominador* das normalizações — a norma do cosseno e o $|d|/\text{avgdl}$ do BM25 deixam de ser dominados por palavras sem poder discriminativo. Já o stemming não remove token algum, mas funde formas flexionadas e reduz o vocabulário em 38% (7044 → 4403): o efeito é sobre a *cobertura* do casamento léxico, permitindo que uma consulta com *solutions* case com um documento que diz *solution*. Como um ataca a normalização e o outro a cobertura, somam-se. Vale notar que o stemming sozinho (0,295) supera as stopwords sozinhas (0,283), o que é coerente com uma coleção de textos científicos, onde a variação morfológica é intensa. Todos os resultados seguintes usam a configuração vencedora (**stop + stem**).




Figura 1. MAP e P@10 nas quatro configurações de pré-processamento.

4.2 Comparação entre os modelos

Modelo	P@10	R@10	F1@10	MAP	MRR	NDCG@10
Vetorial	0,217	0,378	0,249	0,276	0,487	0,326
BM25	0,234	0,398	0,266	0,305	0,539	0,355
Δ relativo	+8,0%	+5,0%	+7,0%	+10,3%	+10,7%	+8,7%

Tabela 2. Métricas agregadas sobre as 225 consultas.

O BM25 é superior em *todas* as métricas, com vantagem maior no MRR (+10,7%) e no MAP (+10,3%) — ou seja, ganha sobretudo no

topo do ranking. A curva precisão-revocação (Figura 2) mostra que a vantagem se mantém em *todos* os 11 níveis de revocação, e não apenas em média.

A média, porém, esconde o essencial: o BM25 vence em 137 consultas, **perde em 81** e empata em 7. A dispersão da Figura 3 confirma que há um número expressivo de consultas abaixo da diagonal. A pergunta interessante não é qual modelo tem a maior média, mas o *que separa* as consultas dos dois grupos.




Figura 2. Curva precisão × revocação interpolada em 11 pontos.

4.3 Análise por consulta

Caso	Q	Mod	1°	2°	3°	4°	5°	AP
BM25 > vet.	q223	vet.	1008	864	1399	400●	1359	0,19
		BM25	1399	400●	1398●	419	1387●	0,46
BM25 > vet.	q59	vet.	382	383	842	786●	1154	0,11
		BM25	785●	381	1154	149	786●	0,37
vet. > BM25	q113	vet.	265●	748●	594	1272	716	0,51
		BM25	704	815	748●	638	708	0,15
vet. > BM25	q190	vet.	390●	391●	1008	15●	627	0,72
		BM25	390●	627	856	1339	15●	0,38
ambos ruins	q124	vet.	941	898	938	1070	516	0,00
		BM25	941	516	898	442	934	0,00
ambos ruins	q13	vet.	496	903	520	643	313	0,01
		BM25	496	903	520	313	440	0,01

Tabela 3. Top-5 de cada modelo nas seis consultas selecionadas. Identificadores de documento; **negrito●** = relevante (grau ≥ 1).

A seleção é automática: entre as consultas com ao menos 4 relevantes, as duas de maior e menor ΔAP e as duas de menor AP médio. Lendo os Top-5 lado a lado, aparece um padrão nítido — e é um padrão de **comprimento de documento**.

(i) **BM25 claramente superior — q223 e q59.** Em q223 (*shear buckling of unstiffened rectangular plates*), o modelo vetorial coloca no topo os documentos 1008 (51 tokens) e 864 (29 tokens), ambos irrelevantes e *muito curtos*, e só encontra um relevante na 4ª posição. O BM25 recupera na 3ª e 5ª posições os documentos 1398 (115 tokens) e 1387 (120 tokens), ambos relevantes e *longos*. A causa é a normalização: o cosseno divide pela norma *completa* do vetor, o que penaliza integralmente um documento longo, mesmo quando o comprimento vem de tratar o assunto com profundidade; o BM25 com $b = 0,75$ normaliza apenas parcialmente. Em q59 ocorre o mesmo: o vetorial promove o documento 382 (21 tokens) e o BM25 encontra o relevante 785 já na 1ª posição.

(ii) **Modelo vetorial superior — q113 e q190.** O mecanismo é o *mesmo*, com o sinal trocado. Em q113 o BM25 traz para o topo os documentos 704 (185 tokens), 815 (142) e 638 (138) — todos longos e todos irrelevantes —, enquanto o vetorial acerta as duas primeiras posições com os documentos 265 (49 tokens) e 748 (83). Aqui os relevantes são curtos e específicos, e a normalização integral do

cosseno é exatamente o que se quer. Em q190 o vetorial coloca três relevantes no Top-4 e o BM25 intercala os documentos 856 (137) e 1339 (130), não relevantes. Em outras palavras: a normalização parcial do BM25 é uma *aposta* — paga bem quando os relevantes são longos e custa caro quando são curtos.

(iii) **Ambos insatisfatórios — q124 e q13.** Estas revelam limitações que nenhum ajuste de ranqueamento resolve. A q13 (*what is the basic mechanism of the transonic aileron buzz*) tem, na 1ª posição de ambos os modelos, o documento 496, “*a theory of transonic aileron buzz, neglecting viscous effects*” — o casamento léxico é quase perfeito, e mesmo assim o julgamento é **-1**, isto é, não relevante. A q124 é uma consulta *composta*, com duas necessidades de informação distintas (escoamento em canais delgados e estabilidade de cascas cônicas); o documento 941, cujo título praticamente repete a primeira metade da consulta, também é julgado **-1**. Ou seja, o erro não está no ranqueamento, mas no descompasso entre *sobreposição léxica* e *relevância julgada*: o avaliador julgou contra a necessidade real, que os modelos não enxergam.

4.4 Verificando a hipótese do comprimento

A leitura acima é uma hipótese construída sobre seis consultas. Testamo-la sobre as 225. Se a normalização for mesmo o mecanismo dominante, então (a) o Top-10 do BM25 deve ser em média mais longo que o do vetorial e (b) o BM25 deve levar vantagem justamente nas consultas cujos relevantes são longos.

Ambas se confirmam. O comprimento médio da coleção é 92,1 tokens e o dos documentos relevantes é 92,5 — praticamente idêntico, ou seja, *ser longo não torna um documento relevante*. Ainda assim, o Top-10 do modelo vetorial tem em média 79,4 tokens (bem abaixo da média da coleção) e o do BM25, 98,4 (acima). O vetorial tem, portanto, um **viés sistemático para documentos curtos** que não é justificado pelos dados. E a correlação de Spearman entre ΔAP (BM25 – vetorial) e o comprimento médio dos relevantes de cada consulta é $\rho = 0,432$ ($p \approx 1e-11$, $n = 225$). A hipótese levantada a partir de seis exemplos resiste, portanto, a um teste sobre a coleção inteira.




Figura 3. AP por consulta. Pontos acima da diagonal favorecem o BM25.

4.5 Variação dos parâmetros do BM25

$k_1 \setminus b$	0 (MAP)	0,75 (MAP)	1 (MAP)	0,75 (P@10)	0,75 (NDCG)
0,5	0,268	0,291	0,294	0,221	0,338
1,2	0,277	0,305	0,306	0,234	0,355
2,0	0,281	0,312	0,308	0,241	0,363

Tabela 4. Grade $k_1 \times b$. As três últimas colunas fixam $b = 0,75$.




Figura 4. MAP do BM25 na grade de parâmetros. A cor codifica a magnitude; o valor está impresso em cada célula.

O melhor ponto da grade é $k_1 = 2,0$, $b = 0,75$, com MAP 0,312 e P@10 0,241. O resultado mais claro é que **b importa muito mais que k_1** : fixado k_1 , passar de $b = 0$ para $b = 0,75$ melhora o MAP entre 8,6% e 10,8%, enquanto variar k_1 de 0,5 a 2,0 com b fixo rende no máximo 7%. Coerente com a §4.4 — a normalização por comprimento é o fator dominante nesta coleção. Também há *interação* entre os parâmetros: para k_1 pequeno (0,5 e 1,2) o melhor b é 1,0, mas para $k_1 = 2,0$ o melhor é 0,75. A leitura é que k_1 alto deixa o score mais sensível à frequência bruta, e aí uma normalização total ($b = 1$) passa a penalizar demais documentos longos que acumulam ocorrências legítimas; um pouco de folga ($b = 0,75$) compensa.

Efeito de b em uma consulta concreta. A q67 (“*can series expansions be found for the boundary layer on a flat plate in a...*”, 14 relevantes) é o caso mais didático.

b	1°	2°	3°	4°	5°	AP
0,0	9	72	1107	155	2●	0,14
0,75	393●	180●	4●	3●	306	0,49
1,0	3●	393●	180●	4●	664●	0,55

Tabela 5. Top-5 da consulta q67 para três valores de b ($k_1 = 1,2$).

Com $b = 0$ não há normalização alguma e o Top-5 é tomado por documentos de 177, 164, 138, 130 e 116 tokens, dos quais apenas o último é relevante: sem normalização, o score cresce com o tamanho, pois documentos longos simplesmente acumulam mais ocorrências dos termos da consulta. Com $b = 0,75$ o ranking se inverte por completo — os cinco primeiros passam a ter 34, 36, 47, 17 e 91 tokens, e quatro são relevantes. Com $b = 1$ os cinco são relevantes e a AP vai de 0,14 para 0,55. Os documentos relevantes desta consulta são artigos curtos e diretamente sobre o tema (“*the boundary layer in simple shear flow past a flat plate*”, 17 tokens); sem normalização eles são esmagados por textos longos que mencionam os mesmos termos de passagem.

4.6 Reformulação de consultas

Cinco consultas foram reescritas *manualmente*, cada uma com uma operação diferente e com a hipótese registrada no código *antes* de rodar os modelos.

Cons.	Operação	AP vetorial	AP BM25	NDCG@10 BM25
q219	sinônimo	0,04 → 0,12	0,04 → 0,09	0,00 → 0,09
q69	+ específica	0,02 → 0,05	0,04 → 0,09	0,00 → 0,17
q109	+ específica (curta)	0,03 → 0,04	0,04 → 0,06	0,00 → 0,03
q171	- termos	0,31 → 0,32	0,64 → 0,56	0,66 → 0,61
q15	vocabulário	0,62 → 0,58	1,00 → 1,00	0,74 → 1,00

Tabela 6. Efeito das reformulações (original → modificada).

q219 — sinônimo. O caso mais limpo. A consulta original diz “...when the reynolds number is *small*”, mas a literatura consagrou a expressão “low Reynolds number”. Trocando uma *única* palavra, *small* por *low*, a AP do vetorial vai de 0,045 para 0,119 e a do BM25 de 0,037 para 0,093 — e a P@10, que era zero nos dois modelos, passa a 0,10. Nada mudou no significado da pergunta; mudou apenas o vocabulário. É a ilustração mais direta da limitação apontada na Aula 04: modelos puramente léxicos não enxergam sinonímia.

q69 e q109 — tornar mais específica. Ambas confirmam a hipótese, com ganho modesto. Em q69 os termos originais são todos pouco discriminativos (*solution*, *boundary*, *layer* e *equation* ocorrem em 400 a 470 dos 1400 documentos); acrescentar *series*, *laminar* e *compressible* leva a AP do BM25 de 0,039 a 0,092 e a $R@10$ de 0 a 0,20. Em q109, uma consulta de apenas 4 tokens, explicitar a consequência física (tensão térmica, flambagem, flutter) leva a $P@10$ de 0 a 0,10.

q171 — remover termos: hipótese parcialmente refutada. Prevíamos que enxugar a consulta de 17 tokens beneficiaria sobretudo o modelo vetorial, prejudicado pela diluição da norma. O vetorial de fato melhorou um pouco (0,306 $\rightarrow$ 0,319), mas o **BM25 piorou** (0,639 $\rightarrow$ 0,556). A explicação é que o BM25 não normaliza o vetor de consulta: termos adicionais só *somam* evidência, e mesmo termos de IDF baixo contribuem positivamente quando presentes. Remover termos, para o BM25, é descartar evidência sem contrapartida — o que revela uma assimetria entre os modelos que não havíamos previsto.

q15 — vocabulário técnico e o valor da métrica graduada. O termo *photoelastic* ocorre em um único documento, mas os dois relevantes usam *photo-thermoelastic*, que o tokenizador quebra em *photo* e *thermoelast* — o stemming não aproxima essas formas. Adotando o termo dos autores, a AP do BM25 *não muda* (1,00 $\rightarrow$ 1,00), porque os dois relevantes já estavam no topo; mas o **NDCG@10 sobe de 0,74 para 1,00**, pois a reformulação reordenou os dois relevantes, trazendo para a 1ª posição o de grau 1 (“resposta completa”). É um bom argumento a favor de reportar métricas graduadas: a AP é cega a uma melhora que o usuário perceberia.

4.7 Análise de erros

Falsos positivos. Escolhemos documentos não relevantes trazidos pelo BM25 para as duas primeiras posições. (1) Na q98, o documento 638 (“*longitudinal aerodynamic characteristics at low subsonic speeds of a highly swept wing utilizing nose flaps*”, grau -1) aparece em 1º com score 35,1. A decomposição do score mostra de onde ele vem: *flap* (+6,74), *control* (+5,70), *trail* (+4,87), *subson* (+3,03). Todos os termos da consulta estão lá — mas a consulta pergunta se controles *na ponta* se comparam a *flaps de bordo de fuga*, e o documento trata de *flaps de nariz*. É a hipótese de **independência entre termos** falhando: o modelo soma evidências isoladas e não percebe que a consulta pede uma *relação* entre elas. (2) Na q124, o documento 941 tem título quase idêntico a metade da consulta e recebe +8,40 só de *channel* ($n=17$, IDF altíssimo), mas é julgado -1, porque a necessidade real de informação está na *outra* metade da consulta. (3) Um terceiro caso, na q139, é de outra natureza: os documentos 847 e 897 estão em 1º e 2º e parecem genuinamente pertinentes, mas simplesmente **não foram julgados**. Como o enunciado manda tratar não julgados como não relevantes, eles contam como erro — o que é, na verdade, uma limitação de cobertura dos qrels do Cranfield, não do sistema.

Falso negativo. Na q80 (“*are methods of measuring aerodynamic derivatives available which could be adopted for use in short running time facilities*”), o documento 596 tem grau 3 e aparece na posição **1206** em ambos os modelos. O motivo é categórico: a interseção entre os tokens da consulta e os do documento é **vazia**. O documento se chama “*the properties of crossed flexure pivots...*” e descreve o *aparato* usado na medição, enquanto a consulta descreve o *método* e a *finalidade*. Score zero não é um erro de ponderação: é o limite do casamento léxico. Nenhum ajuste de k_1 , b ou pré-processamento recupera esse documento — seria preciso representação semântica (embeddings) ou expansão de consulta. Os outros dois falsos negativos que examinamos têm a mesma assinatura: no documento 236 da q87 (grau 4), o único termo casado é *flow*, o de menor IDF da consulta ($n = 730$ de 1400).

5. Considerações finais

1. O pré-processamento é barato e vale a pena. Stopwords e stemming juntos elevam o MAP do BM25 em 13,2%, e são complementares porque atacam frentes distintas: um corrige o

denominador das normalizações, o outro amplia a cobertura do casamento léxico.

2. O BM25 vence, mas não por ser “melhor” em abstrato. Ele supera o vetorial em todas as métricas (MAP +10,3%) e em todos os níveis de revocação, mas perde em 81 das 225 consultas. A diferença é governada pela normalização por comprimento: o cosseno normaliza integralmente e adquire um viés para documentos curtos (Top-10 médio de 79,4 tokens contra 92,1 da coleção), enquanto o BM25 normaliza parcialmente. Confirmamos isso com $\rho = 0,43$ entre ΔAP e o comprimento dos relevantes.

3. b importa mais que k_1 , e os dois interagem: o melhor b cai de 1,0 para 0,75 quando k_1 cresce de 1,2 para 2,0.

4. O teto dos dois modelos é léxico. As consultas em que ambos falham não falham por ranqueamento: ou o documento relevante não compartilha *nenhum* termo com a consulta, ou a consulta é composta, ou o julgamento não acompanha a sobreposição léxica. Trocar “*small*” por “*low*” em q219 quase triplicou a AP — um ganho que nenhum ajuste de parâmetro produziria. É exatamente onde entram expansão de consulta e representações densas.

5. A escolha da métrica muda o diagnóstico. A AP não viu a melhora da reformulação de q15, que o NDCG@10 registrou (0,74 $\rightarrow$ 1,00); e o NDCG varia 17% conforme se corrija ou não a escala invertida do Cranfield. Decisões de avaliação merecem tanta atenção quanto decisões de modelagem.

6. Uso de ferramentas de IA

Ferramentas de IA generativa (Claude) foram utilizadas como apoio nas seguintes atividades: **(i) apoio à programação** — estruturação dos módulos, vetorização com matrizes esparsas e escrita dos testes automatizados; **(ii) depuração** — diagnóstico de uma instalação corrompida do SciPy causada pelo limite de 260 caracteres de caminho do Windows, e identificação do desalinhamento entre os identificadores .I das consultas e a numeração do *cranqrel*; **(iii) explicação de conceitos** — discussão das variantes de IDF do BM25 e das convenções de ganho do NDCG; e **(iv) revisão textual** deste relatório. As fórmulas, as decisões de implementação, o desenho dos experimentos, as reformulações manuais de consulta e a interpretação dos resultados foram revisados e são de responsabilidade dos autores, que compreendem integralmente o código entregue.

Referências

- [1] MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [2] ROBERTSON, S.; ZARAGOZA, H. *The Probabilistic Relevance Framework: BM25 and Beyond*. Foundations and Trends in IR, 2009.
- [3] SALTON, G.; WONG, A.; YANG, C. S. A Vector Space Model for Automatic Indexing. *Communications of the ACM*, v. 18, n. 11, 1975.
- [4] CLEVERDON, C. W. The Cranfield tests on index language devices. *Aslib Proceedings*, 1967.
- [5] JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated Gain-based Evaluation of IR Techniques. *ACM TOIS*, v. 20, n. 4, 2002.